

Tenemos un modelo $Y_i = B_0 + B_1 X_i + E_i$. Asumimos que el error tiene una distribución normal $N(0, \sigma^2)$.
Distribución de la variable respuesta (parte aleatoria) = $Y_i \sim N(u_i, \sigma^2)$ Predictor lineal (parte
 $N_i = B_0 + B_1 X_i$ Enlace (función de enlace) = $u_i = N_i$ El modelo lineal es bien flexible. Podemos modelar un mo-

OJO: imaginemos que quieres modelar el salario con la edad. Este sigue una curva no lineal cóncava. Podemos pensar el modelo como el siguiente: Parte aleatoria $Y_i \sim N(u_i, \sigma^2)$ Predictor lineal = $N_i = B_0 + B_1 X_i + B_2 X_i^2$ al cuadrado Enlace = $u_i = N_i$

Podría incluso partir la función cóncava en particiones y modelar la función mediante funciones indicadoras.

Para cada valor de X_i tienes una distribución de la Y_i (ver gráfico inkscape).

Imaginemos que queremos modelar el conteo. Entonces nuestra variable aleatoria tendría distribución $Y_i \sim \text{pois}(u_i)$, nuestro predictor lineal sería $N_i = B_0 + B_1 X_i$ y la función de enlace sería $u_i = N_i$.

Modelo logístico: $Y_i \sim \text{Bernoulli}(u_i)$; $N_i = B_0 + B_1 X_i$; $\log(u_i/(1 - u_i)) = N_i$.

Esto da pie a indicar los modelos lineales generalizados. En donde $Y_i \in \text{Familia} - \text{exponencial}(u_i, \phi)$, en donde ϕ es un parámetro de dispersión. La familia exponencial es la siguiente: Normal, Gamma, Normal Inversa, Poisson, Bernoulli. Doblemente diferenciable y monótona.

Modelo aditivo generalizado: Asumo que los efectos de las covariables son aditivos.

Todos los modelos que se han mostrado hasta ahora sirven para modelar la media. Por otro lado, la regresión cuantílica sirve para modelar cuantiles.

Se tiene un modelo $Y_i = B_0 + B_1 X_{i1} + B_2 X_{i2} + \dots + B_k X_{ik} + E_i$, $i = 1, 2, \dots, n$. Es más práctico evaluar todo de forma matricial.

Se tiene entonces $Y = (Y_1, Y_2, \dots, Y_n)^T$, $B = (B_0, B_1, \dots, B_k)$, $X = (1, X_{11}, \dots, X_{1k}, \dots, 1, X_{n1}, \dots, X_{nk})$

y $E = (e_1, e_2, \dots, e_n)^T$

Entonces todo se puede evaluar como $Y = XB + E$; $E \sim N(0, \sigma^2 I)$ (-identidad-) El estimador de mínimos cuadrados ordinarios es: $\sum_{i=1}^n E_i^2$ al cuadrado = $(E)^T E = (Y - XB)^T (Y - XB)$ LS(B) = $(Y)^T Y - 2(Y)^T XB + (B)^T (X)^T XB$.

Entonces, derivamos la suma de los cuadrados en relación a β y sale = $-2(X)^T Y + 2(X)^T X B = 0$ Luego tenemos que $((X)^T X)^{-1} (X)^T X B = ((X)^T X)^{-1} (X)^T Y$ se cancela el argumento de la izquierda y se tiene que $B = ((X)^T X)^{-1} (X)^T Y$

Luego tenemos que verificar que el estimador es insesgado y con varianza mínima. A este B hay que hallar la esperanza. Utilizamos el TB2 - prueba 2. y obtenemos que: $E(B \text{ estimado}) = E(((X)^T X)^{-1} (X)^T Y) = ((X)^T X)^{-1}$

ver pantalla de celular. dos imágenes.

El VIF es el factor de inflación de varianza $(1/(1 - R^2_j))$.

Vamos a probar que el estimador de B de mínimos cuadrados ordinarios es el mejor que hay.

Ver la segunda pantalla de celular. Es un huevo!! XD