

## El parámetro de dispersión

La familia exponencial es escrita en la siguiente forma

$$f_Y(y; \theta, \phi) = \exp \left\{ \frac{y\theta - B(\theta)}{\phi} + C(y, \phi) \right\}, \quad (1)$$

donde  $B(\cdot)$  y  $C(\cdot, \cdot)$  son funciones conocidas, y el rango de  $Y$  no depende de  $\theta$  o  $\phi$ . En este caso, llamamos a  $\theta$  el *parámetro canónico*, y  $\phi$  el *parámetro de dispersión*. Si la distribución es parameterizada en términos de la media de  $Y$ ,  $\mu$ , entonces  $\theta \equiv g(\mu)$  para alguna función  $g$ , luego  $g(\mu)$  es la función de enlace canónica.

NOTA: Para una v.a.  $Y$  con distribución de la forma (1),

$$\mu \equiv E[Y] = B'(\theta)$$

y

$$\text{Var}[Y] = B''(\theta)\phi \equiv V(\mu)\phi.$$

Aquí  $V$  es llamada *función de varianza*. Así, la función de varianza es igual a  $B''(\theta)$  para familias exponenciales.

## Ejemplo: Distribución Gamma

La f.d.p de una v.a.  $Y$  con distribución  $\text{Gamma}(\alpha, \nu)$ ,  $0 < \alpha, \nu, y < \infty$ , puede ser escrita como

$$\begin{aligned} f_Y(y) &= \frac{y^{\nu-1} \alpha^\nu e^{-y\alpha}}{\Gamma(\nu)} \\ &= \exp \{ -y\alpha + \nu \log \alpha + (\nu - 1) \log y - \log \Gamma(\nu) \} \\ &= \exp \left\{ \frac{y(-\alpha/\nu) - [-\log \alpha]}{1/\nu} + (\nu - 1) \log y - \log \Gamma(\nu) \right\}. \end{aligned}$$

Sea  $\theta \equiv -\alpha/\nu$  y  $\phi \equiv 1/\nu$ ,

$$f_Y(y) = \exp \left\{ \frac{y\theta - [-\log(-\theta)]}{\phi} - \log(\phi)/\phi + (1/\phi - 1) \log y - \log \Gamma(1/\phi) \right\}$$

Luego, la distribución Gamma forma parte de la familia exponencial con  $B(\theta) = -\log(-\theta)$  y parámetro de dispersión  $\phi \equiv 1/\nu$ . Esta definición de  $\phi$  es convencional, y es usada en R. Como

$$\mu \equiv E[Y] = B'(\theta) = -\frac{1}{\theta}$$

y

$$\text{Var}[Y] = B''(\theta)\phi = \frac{\phi}{\theta^2} = \phi\mu^2,$$

esta definición implica que  $V(\mu) = \mu^2$ .

La forma mas facil de encontrar la funcion de enlace canonica de la distribucion gamma es parametrizar en terminos de su media. Asi podemos calcular:

$$f_Y(y) = \exp \left\{ \frac{y \left( -\frac{1}{\mu} \right) - \log(\mu)}{\phi} - \log(\phi)/\phi + (1/\phi - 1) \log y - \log \Gamma(1/\phi) \right\}.$$

Luego, la funcion de enlace canonica es  $g(\mu) = -\frac{1}{\mu}$ .

## MLG para parámetro de dispersión desconocido

En particular, “tratamos”  $\phi$  como conocido y común a todas las observaciones. Luego, dejamos  $\mu$  (y así  $\theta$ ) variar entre las observaciones en la forma usual, es decir. para observaciones  $Y_1, \dots, Y_n$ , asumimos que

$$g(\mu_i) = \sum_{j=1}^p x_{ij} \beta_j.$$

La diferencia entre este modelo y los MLG usuales es que, además de estimar los  $\beta_j$ 's, necesitamos estimar también  $\phi$ . Podemos obtener un estimador usando la estadística de Pearson chi-cuadrado y sus propiedades asintóticas.

## Estimación del parámetro de dispersión

En general, la estadística de Pearson se define como

$$X^2 = \sum_{i=1}^n \frac{(Y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)},$$

donde  $\text{Var}[Y_i] = V(\mu_i)\phi$ .

La estadística de Pearson chi-cuadrado *estandarizada* es definida como

$$X_s^2 = \frac{X^2}{\phi}.$$

Resulta que, si el modelo es especificado correctamente,

$$X_s^2 \sim \chi_{n-p}^2$$

asintóticamente, donde  $n$  es el tamaño de muestra y  $p$  es el número de coeficientes de regresión (los  $\beta_j$ 's) en el modelo.

Como el valor esperado de una v.a.  $\chi_{n-p}^2$  es  $n - p$ , podemos usar la aproximación  $X_s^2 \approx n - p$ , y así un estimador

$$\hat{\phi} = \frac{X^2}{n - p}.$$

Note que este *no* es el EMV de  $\phi$  (es realmente *un estimador de momentos*).

### Ejemplo: Distribución Gamma (cont.)

Para v.a.s independientes  $Y_1, \dots, Y_n$  con  $Y_i \sim \text{Gamma}(\theta_i, \nu)$ ,

$$\begin{aligned}\text{Var}[Y_i] &= B''(\theta)\phi \\ &= \frac{\phi}{\theta^2} \\ &\equiv \mu_i^2 \phi\end{aligned}$$

so  $V(\mu_i) \equiv \mu_i^2$  y

$$X^2 = \sum_{i=1}^n \frac{(Y_i - \hat{\mu}_i)^2}{\hat{\mu}_i^2}.$$

Entonces,

$$\hat{\phi} = \sum_{i=1}^n \frac{(Y_i - \hat{\mu}_i)^2}{\hat{\mu}_i^2(n-p)}.$$

Como los estimadores de momentos también tienen la propiedad de invarianza (como los EMVs), podemos estimar  $\nu$  por

$$\hat{\nu} = \frac{1}{\hat{\phi}}.$$